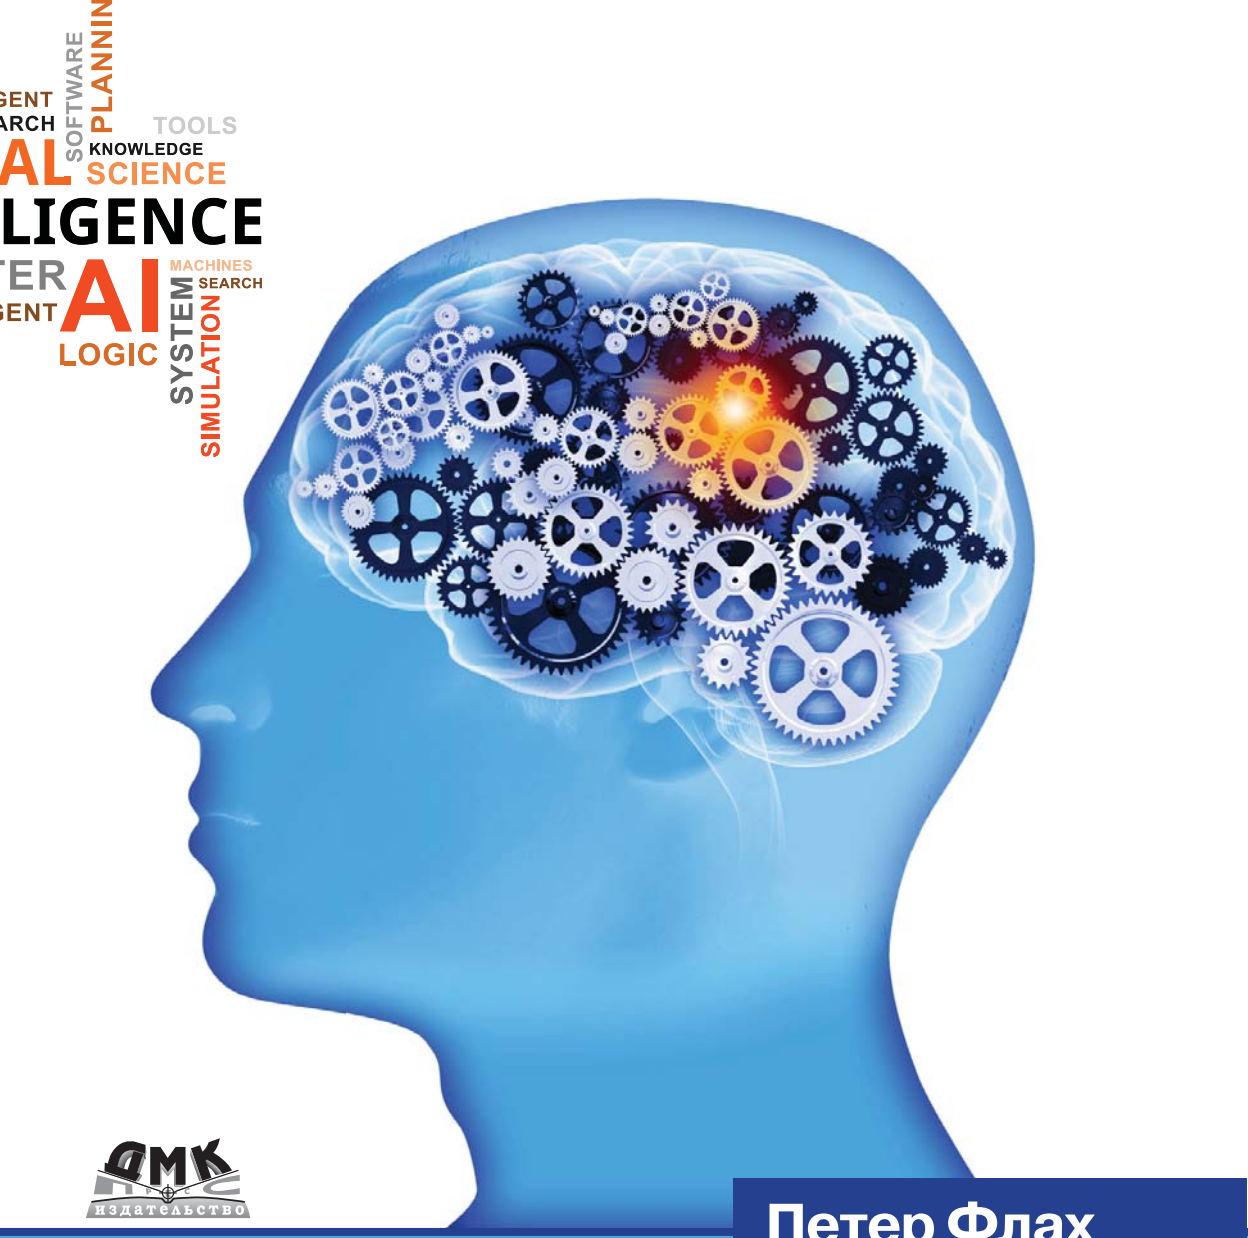

ДМК Пресс
издательство

Петер Флах

Машинное обучение

Наука и искусство построения алгоритмов, которые извлекают знания из данных

УДК 004.4
ББК 32.972
Ф70

Флах П.
Ф70 Машинное обучение. Наука и искусство построения алгоритмов, которые извлекают знания из данных / пер. с англ. А. А. Слинкина. – М.: ДМК Пресс, 2015. – 400 с.: ил.

ISBN 978-5-97060-273-7

Перед вами один из самых интересных учебников по машинному обучению – разделу искусственного интеллекта, изучающего методы построения моделей, способных обучаться, и алгоритмов для их построения и обучения. Автор воздал должное невероятному богатству предмета и не упустил из виду объединяющих принципов. Читатель с первых страниц видит машинное обучение в действии, но без не нужных на первых порах технических деталей. По мере изучения предмета тщательно подобранные примеры, сопровождаемые иллюстрациями, постепенно усложняются.

В книге описан широкий круг логических, геометрических и статистических моделей, затрагиваются и такие находящиеся на переднем крае науки темы, как матричная факторизация и анализ РХП. Особое внимание уделено важнейшей роли признаков. Устоявшаяся терминология дополняется введением в рассмотрение новых полезных концепций. В конце каждой главы приводятся ссылки на дополнительную литературу с авторскими комментариями.

Благодаря всему этому книга задает новый стандарт изучения такой сложной дисциплины как машинное обучение.

Цветные рисунки к книге размещены на нашем сайте www.dmkpress.com

УДК 004.4
ББК 32.972

This publication is in copyright. Subject to statutory exception and to the provisions of relevant collective licensing agreements, no reproduction of any part may take place without the written permission of Cambridge University Press. First published 2012.

Все права защищены. Любая часть этой книги не может быть воспроизведена в какой бы то ни было форме и какими бы то ни было средствами без письменного разрешения владельцев авторских прав.

Материал, изложенный в данной книге, многократно проверен. Но поскольку вероятность технических ошибок все равно существует, издательство не может гарантировать абсолютную точность и правильность приводимых сведений. В связи с этим издательство не несет ответственности за возможные ошибки, связанные с использованием книги.

ISBN 978-1-107-09639-4 (анг.)
ISBN 978-5-97060-273-7 (рус.)

© Peter Flach 2012
© Издание, перевод, ДМК Пресс, 2015

Содержание

Предисловие **11**

Как читать эту книгу 11

Благодарности 12

Пролог: пример машинного обучения **14**

1 Ингредиенты машинного обучения **25**

1.1 Задачи: проблемы, решаемые методами машинного обучения 25

В поисках структуры 27

Оценка качества решения задачи 30

1.2 Модели: результат машинного обучения 32

Геометрические модели 33

Вероятностные модели 37

Логические модели 44

Группировка и ранжирование 49

1.3 Признаки: рабочая лошадка машинного обучения 50

Два способа использования признаков 52

Отбор и преобразование признаков 54

Взаимодействие между признаками 56

1.4 Итоги и перспективы 59

Что будет в книге дальше 61

2 Бинарная классификация и родственные задачи **62**

2.1 Классификация 65

Оценка качества классификации 66

Наглядное представление качества классификации 70

2.2 Оценивание и ранжирование 75

Оценка и визуализация качества ранжирования 78

Преобразование ранжировщика в классификатор 84
2.3. Оценивание вероятностей классов 87
Качество оценивания вероятностей классов 88
Преобразование ранжировщиков в оценки вероятностей классов 91
2.4 Бинарная классификация и родственные задачи: итоги и дополнительная литература 93

3 За пределами бинарной классификации 96

3.1 Когда классов больше двух 96
Многоклассовая классификация 96
Многоклассовые оценки и вероятности 101
3.2 Регрессия 105
3.3 Обучение без учителя и дескриптивные модели 108
Прогностическая и дескриптивная кластеризация 109
Другие дескриптивные модели 114
3.4 За пределами бинарной классификации: итоги и литература для дальнейшего чтения 116

4 Концептуальное обучение 118

4.1 Пространство гипотез 119
Наименьшее обобщение 120
Внутренняя дизъюнкция 122
4.2 Пути в пространстве гипотез 124
Наиболее общие непротиворечивые гипотезы 128
Замкнутые концепты 130
4.3 За пределами конъюнктивных концептов 130
Применение логики первого порядка 135
4.4 Обучаемость 136
4.5 Концептуальное обучение: итоги и литература для дальнейшего чтения 139

5 Древовидные модели 142

5.1 Решающие деревья 146
5.2 Деревья ранжирования и оценивания вероятностей 151
Чувствительность к асимметричному распределению по классам 156
5.3 Обучение деревьев как уменьшение дисперсии 161
Деревья регрессии 161
Кластеризующие деревья 165

5.4 Древовидные модели: итоги и литература для дальнейшего чтения 168

6 Модели на основе правил.....170

6.1 Обучение упорядоченных списков правил..... 170
Списки правил для ранжирования и оценивания вероятностей..... 176
6.2 Обучение неупорядоченных множеств правил..... 179
Применение множеств правил для ранжирования и оценивания вероятностей..... 183
Более пристальный взгляд на перекрытие правил 187
6.3 Обучение дескриптивных моделей на основе правил 189
Обучение правил для выявления подгрупп 190
Добыча ассоциативных правил..... 194
6.4 Обучение правил первого порядка..... 199
6.5 Модели на основе правил: итоги и литература для дальнейшего чтения..... 203

7 Линейные модели.....206

7.1 Метод наименьших квадратов 208
Многомерная линейная регрессия 212
Регуляризованная регрессия 216
Применение регрессии по методу наименьших квадратов к задаче классификации 217
7.2 Перцептрон 218
7.3 Метод опорных векторов 223
Метод опорных векторов с мягким зазором..... 228
7.4 Получение вероятностей от линейных классификаторов..... 231
7.5 За пределами линейности – ядерные методы..... 236
7.6 Линейные модели: итоги и литература для дальнейшего чтения..... 239

8 Метрические модели 242

8.1 Так много дорог..... 242
8.2 Соседи и эталоны..... 248
8.3 Классификация по ближайшему соседу..... 253
8.4 Метрическая кластеризация..... 256
Алгоритм K средних 259
Кластеризация вокруг медоидов..... 261
Силуэты..... 262
8.5 Иерархическая кластеризация..... 264

8.6 От ядер к расстояниям ... 269
8.7 Метрические модели: итоги и литература для дальнейшего чтения ... 270

9 Вероятностные модели ... 273

9.1 Нормальное распределение и его геометрические интерпретации ... 277
9.2 Вероятностные модели для категориальных данных ... 284
Использование наивной байесовской модели для классификации ... 286
Обучение наивной байесовской модели ... 289
9.3 Дискриминантное обучение путем оптимизации условного правдоподобия ... 293
9.4 Вероятностные модели со скрытыми переменными ... 297
EM-алгоритм ... 299
Гауссовы смесовые модели ... 300
9.5 Модели на основе сжатия ... 304
9.6 Вероятностные модели: итоги и литература для дальнейшего чтения ... 306

10 Признаки ... 310

10.1 Виды признаков ... 310
Вычисления с признаками ... 311
Категориальные, порядковые и количественные признаки ... 315
Структурированные признаки ... 317
10.2 Преобразования признаков ... 318
Задание порога и дискретизация ... 319
Нормировка и калибровка ... 325
Неполные признаки ... 333
10.3 Конструирование и отбор признаков ... 334
Преобразование и разложение матриц ... 336
10.4 Признак: итоги и литература для дальнейшего чтения ... 339

11 Ансамбли моделей ... 342

11.1 Баггинг и случайные леса ... 343
11.2 Усиление ... 345
Обучение усиленных правил ... 349
11.3 Карта ансамблевого ландшафта ... 350
Смещение, дисперсия и зазоры ... 350
Другие ансамблевые методы ... 352
Метаобучение ... 352

11.4 Ансамбли моделей: итоги и литература для дальнейшего чтения 353

12 Эксперименты в машинном обучении 355

12.1 Что измерять 356
12.2 Как измерять 360
12.3 Как интерпретировать..... 362
Интерпретация результатов, полученных на нескольких наборах данных..... 365
12.4 Эксперименты в машинном обучении: итоги и литература для дальнейшего чтения..... 368

Эпилог: что дальше? 371

Что нужно запомнить.....373

Библиография.....376

Предметный указатель.....387

Глава 1

Ингредиенты машинного обучения

Смысл машинного обучения состоит в использовании нужных признаков для построения моделей, подходящих для решения правильно поставленных задач, – этой фразой, наглядно представленной на рис. 3, мы закончили пролог. По существу, *признаки* определяют «язык», на котором описываются объекты предметной области, будь то почтовые сообщения или сложные органические молекулы. Имея представление в виде признаков, мы уже можем не возвращаться к самим объектам предметной области; именно поэтому признаки играют такую важную роль в машинном обучении. В разделе 1.3 мы присмотримся к ним поближе. *Задача* – это абстрактное представление проблемы с участием объектов предметной области, которую мы хотим решить. Чаще всего требуется классифицировать объекты, то есть отнести каждый объект к одному из двух или более классов, но на страницах этой книги мы встретим и другие задачи. Многие задачи можно представить в виде отображения исходных данных на результаты. Такое отображение, или *модель*, само является результатом алгоритма машинного обучения, примененного к обучающим данным. Как мы увидим в разделе 1.2, разнообразие моделей весьма широко.

Мы начнем эту главу с обсуждения задач – проблем, которые можно решить методами машинного обучения. Различных моделей очень много, но, как выясняется, все они предназначены для решения узкого круга задач и пользуются немногими типами признаков. Можно сказать, что *модели обеспечивают разнообразие предмета машинного обучения, тогда как задачи и признаки придают ему единство*.

1.1 Задачи: проблемы, решаемые методами машинного обучения

В прологе было описано распознавание почтового спама. Это задача бинарной классификации – пожалуй, самая распространенная в машинном обучении, она будет встречаться нам не раз. Очевидное обобщение – задачи классификации с числом классов больше двух. Так, может быть интересно распознавать различные виды хороших почтовых сообщений, например относящиеся к работе и личные. К этой задаче можно было бы подойти как к комбинации двух задач бинарной классификации: сначала отделить спам от неспама, а затем разбить хорошие

сообщения на рабочие и личные. Однако при этом теряется потенциально полезная информация, поскольку некоторые спамные сообщения выглядят скорее как личные, нежели как рабочие. Поэтому зачастую выгодно рассматривать *многоклассовую классификацию* как самостоятельную задачу машинного обучения. На первый взгляд, ничего особенного: ведь все равно придется обучить модель, чтобы связать класс с признаками. Но при такой, более общей постановке некоторые концепции нуждаются в переосмыслении: например, понятие решающей границы не столь очевидно, как в случае с двумя классами.

Иногда естественно вообще отказаться от дискретных классов, а предсказывать некое вещественное число. Например, что, если требуется оценить срочность входящего сообщения по некоторой шкале? Такая задача называется *регрессией*, суть ее состоит в том, чтобы построить вещественную функцию на основании обучающих примеров, помеченных истинными значениями функции. Например, я мог бы построить такой обучающий набор, случайно выбрав несколько сообщений из ящика «Входящие» и приписав им оценку срочности по шкале от 0 (игнорировать) до 10 (требуется немедленная реакция). Обычно для решения этой задачи выбирают некий класс функций (скажем, функции, линейно зависящие от каких-то числовых признаков) и строят функцию из этого класса, которая минимизирует разность между предсказанными и истинными значениями. Отметим, что существует тонкое различие между этим подходом и обучением SpamAssassin, поскольку в последнем случае обучающий набор был помечен классами, а не «истинными» оценками спама. Это означает, что в распоряжении SpamAssassin меньше исходной информации, но также позволяет нам интерпретировать выданную SpamAssassin оценку как отдаленность сообщения от решающей границы и, следовательно, как меру уверенности SpamAssassin в собственном предсказании. В задаче регрессии понятие решающей границы бессмысленно, поэтому нужно найти другие способы выразить доверие к предсказаниям модели – вещественным числам.

Как классификация, так и регрессия предполагают наличие обучающего набора примеров, помеченных истинными классами или значениями функции. Разметка набора данных нередко оказывается трудоемкой и дорогостоящей работой. Можно ли научиться отличать спам от неспама или рабочую почту от личной, не размечая обучающий набор? Да, до некоторой степени. Задача группировки данных в отсутствие априорной информации о группах называется *кластеризацией*. Обучение на неразмеченных данных называется *обучением без учителя*, оно принципиально отличается от *обучения с учителем*, для которого требуются размеченные обучающие данные. Работа типичного алгоритма кластеризации основана на оценивании сходства между объектами (теми, что мы пытаемся кластеризовать, например почтовыми сообщениями) и помещении похожих экземпляров в один кластер, а непохожих – в разные.

Пример 1.1 (измерение сходства). Если почтовые сообщения описываются признаками в виде вхождения слов, как в примере классификации текста, то схожесть сообщений можно измерить в терминах общих слов. Например, взять количество общих слов в двух сообщениях и разделить его на общее количество слов в обоих сообщениях (такая мера называется *коэффициентом Жаккара*). Пусть одно сообщение содержит 42 (различных) слова, другое – 112 слов, и у этих сообщений имеется 23 общих слова. Тогда мера их сходства равна 23 / (42 + 112 – 23) = 23 / 130 = = 0.18. Далее мы можем разбить сообщения на группы так, чтобы среднее сходство сообщения со всеми остальными сообщениями в его группе было намного больше, чем среднее сходство с сообщениями в любой другой группе. И хотя не стоит ожидать, что таким образом удастся получить два четко разделенных кластера, содержащих спам и неспам, – чудес-то не бывает – кластеры все же могут вскрыть интересные и полезные особенности строения данных. Возможно, удалось бы выявить какой-то особый вид спама, если бы образовалась подгруппа, в которой состав слов или язык отличается от всех остальных сообщений.

Существует еще много закономерностей, которые можно обнаружить в данных в результате обучения без учителя. *Ассоциативные правила* – вид закономерностей, популярных в маркетинговых приложениях, а результатом можно полюбоваться на сайтах многих интернет-магазинов. Например, когда я искал на сайте `www.amazon.co.uk` книгу John Shawe-Taylor, Nello Cristianini «Kernel Methods for Pattern Analysis», то в разделе «Люди, купившие эту книгу, покупали также» мне предложили также следующие издания:

- Nello Cristianini, John Shawe-Taylor «An Introduction to Support Vector Machines and Other Kernel-based Learning Methods»;
- Christopher Bishop «Pattern Recognition and Machine Learning»;
- Trevor Hastie, Robert Tibshirani, Jerome Friedman «The Elements of Statistical Learning: Data Mining, Inference and Prediction»;
- Richard Duda, Peter Hart, David Stork «Pattern Classification»

и еще 34 книги. Такие ассоциации обнаруживаются алгоритмами добычи данных, которые уделяют внимание объектам, часто встречающимся вместе. Обычно в подобных алгоритмах рассматриваются только объекты, встречающиеся не менее некоторого минимального числа раз (поскольку никому не нужны рекомендации, основанные на приобретении всех 39 книг одним покупателем!). Более интересные ассоциации можно найти, анализируя элементы в вашем заказе. Существует много других видов ассоциаций, которые можно выявить и исследовать, например корреляция между вещественными переменными.

В поисках структуры

Как и все прочие модели машинного обучения, закономерности – это проявление особенностей структуры данных. Иногда структура предстает в виде единственной *скрытой*, или *латентной*, *переменной*, наподобие ненаблюдаемых, но тем не менее объяснимых физических величин, скажем, энергии. Рассмотрим следующую матрицу:

$$\begin{pmatrix} 1 & 0 & 1 & 0 \\ 0 & 2 & 2 & 2 \\ 0 & 0 & 0 & 1 \\ 1 & 2 & 3 & 2 \\ 1 & 0 & 1 & 1 \\ 0 & 2 & 2 & 3 \end{pmatrix}.$$

Предположим, что каждая строка содержит оценки по четырехбалльной шкале (от 0 до 3), поставленные шестью разными людьми четырем разным фильмам – скажем, «Побег из Шоушенка», «Подозрительные лица», «Крестный отец» и «Большой Лебовски» (представлены столбцами слева направо). Похоже, что «Крестный отец» – самый популярный фильм из этой четверки со средней оценкой 1.5, а «Побег из Шоушенка» – самый непопулярный со средней оценкой 0.5. Вы видите какую-нибудь структуру в этой матрице?

Если вы готовы ответить «нет», то попробуйте поискать столбцы или строки, являющиеся комбинациями других столбцов или строк. Например, оказывается, что третий столбец – сумма первого и второго. Аналогично четвертая строка – сумма первой и второй. Это означает, что четвертый человек суммировал оценки первого и второго. Точно так же оценки «Крестного отца» – это сумма оценок первых двух фильмов. Это станет наглядно видно, если записать матрицу в виде следующего произведения:

$$\begin{pmatrix} 1 & 0 & 1 & 0 \\ 0 & 2 & 2 & 2 \\ 0 & 0 & 0 & 1 \\ 1 & 2 & 3 & 2 \\ 1 & 0 & 1 & 1 \\ 0 & 2 & 2 & 3 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix} \times \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{pmatrix} \times \begin{pmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 1 \end{pmatrix}.$$

Возможно, вам кажется, что я только сделал хуже – вместо одной матрицы у нас теперь целых три! Заметим, однако, что первая и третья матрицы в правой части содержат только нули и единицы, а средняя – диагональная (все элементы вне главной диагонали равны нулю). И что важнее, у этих матриц есть очень естественная интерпретация в терминах *жанров* фильмов. Самая правая матрица ассоциирует фильмы (по столбцам) с жанрами (по строкам): «Побег из Шоушенка» и «Подозрительные лица» относятся к двум разным жанрам, назовем их драма и криминальный фильм, «Крестный отец» – к тому и другому, а «Большой Лебовски» – это одновременно криминальный фильм и представитель еще одного жанра (комедии). Высокая матрица размерности 6×3 описывает предпочтения людей в терминах жанров: первый, четвертый и пятый рецензенты любят драмы, второй, четвертый и пятый – криминальные фильмы, а третий, пятый

и шестой – комедии. И наконец, средняя матрица говорит, что криминальный жанр в два раза важнее остальных двух, если оценивать его с точки зрения предпочтений зрителей.

Методы обнаружения таких скрытых переменных, как жанры фильмов, демонстрируют свои истинные возможности, когда количество значений скрытой переменной (здесь количество жанров) намного меньше количества строк и столбцов в исходной матрице. Например, на момент написания книги на сайте www.imdb.com было представлено примерно 630 000 оцененных фильмов, за которые проголосовало 4 миллиона посетителей, но категорий фильмов было всего 27 (включая и вышеупомянутые). Хотя было бы наивно полагать, что оценка фильма определяется исключительно жанром, – границы жанров часто размыты, к тому же кому-то, возможно, нравятся только комедии, снятые братьями Коэн, – такой вид ☞ *разложения матрицы* часто вскрывает полезную скрытую структуру. Мы еще вернемся к этой теме в главе 10.

Настал подходящий момент, чтобы ввести терминологию, которой мы будем пользоваться в этой книге. Мы уже видели различие между обучением с учителем по размеченным данным и обучением без учителя по неразмеченным данным. Аналогично можно провести различие в зависимости от того, подразумевает модель вычисление некоей целевой переменной или нет: если да, модель будет называться *прогностической*, иначе *дескриптивной*. Таким образом, мы получаем четыре разновидности машинного обучения, перечисленные в табл. 1.1.

- ☞ Чаще всего встречаются прогностические модели, обученные с учителем, – на самом деле именно это обычно и имеется в виду, когда говорят об обучении с учителем. Типичные задачи – классификация и регрессия.
- ☞ Размеченный обучающий набор можно использовать также для построения дескриптивной модели, цель которой – не спрогнозировать значение целевой переменной, а, скажем, выявить подмножества данных, которые обладают специфическим поведением относительно целевой переменной. Этот конкретный пример обучения дескриптивной модели с учителем называется *выявлением подгрупп*; мы займемся им в разделе 6.3.
- ☞ Дескриптивные модели можно естественно обучить без учителя, и такие примеры нам уже встречались (кластеризация, выявление ассоциативных правил и разложение матрицы). Часто именно это имеют в виду, говоря об обучении без учителя.
- ☞ Типичный пример обучения прогностической модели без учителя – кластеризация данных с намерением использовать кластеры для присвоения меток классов новым данным. Мы будем называть это *прогностической кластеризацией*, чтобы отличить от *дескриптивной* формы кластеризации.

Существует еще и пятая разновидность – обучение прогностических моделей *с частичным привлечением учителя*, хотя в этой книге мы ее касаться не будем. Во многих предметных областях получить просто данные легко, но вот получить размеченные данные дорого. Например, для классификации веб-страниц в вашем распоряжении вся Всемирная паутина, но чтобы построить размеченный

	Прогностическая модель	*Дескриптивная модель*
Обучение с учителем	Классификация, регрессия	Выявление подгрупп
Обучение без учителя	Прогностическая кластеризация	Дескриптивная кластеризация, выявление ассоциативных правил

Таблица 1.1. Разновидности машинного обучения. В строках указано, помечены ли обучающие данные целевой переменной, а в столбцах – используются ли модели для предсказания целевой переменной или для описания имеющихся данных

обучающий набор, придется приложить немало усилий. Один из возможных подходов – взять небольшой размеченный набор для построения начальной модели, а затем уточнить ее с помощью неразмеченных данных; это и называется обучением с частичным привлечением учителя. Например, начальную модель можно было бы использовать для предсказания характеристик неразмеченных данных, взять самые надежные предсказания в качестве новых обучающих данных и переобучить модель на расширенном обучающем наборе.

Оценка качества решения задачи

Говоря о проблемах машинного обучения, важно понимать, что у них нет одного «правильного» решения. Этим они отличаются от многих других знакомых вам проблем информатики. Например, у задачи сортировки записей адресной книги по алфавиту есть единственный правильный результат (если только в ней не встречаются два человека с одинаковой фамилией, но тогда для устранения неопределенности можно взять еще какое-то поле, скажем, имя или возраст). Это не значит, что существует единственный способ достижения результата, – напротив, имеется множество алгоритмов сортировки: сортировка вставками, пузырьковая сортировка, быстрая сортировка и т. д. При сравнении качества работы этих алгоритмов мы принимали бы во внимание их скорость и максимальный объем обрабатываемых данных. Например, можно было бы экспериментально проверить алгоритм на реальных данных или проанализировать его методами теории вычислительной сложности. Однако мы не учитывали бы при сравнении правильность результата, потому что алгоритм, который иногда упорядочивает данные, а иногда нет, вообще бесполезен в качестве алгоритма сортировки.

Совсем иначе обстоит дело в машинном обучении (и не только в нем, см. замечание 1.1). Можно с уверенностью предположить, что идеального фильтра почтового спама не существует – иначе спамеры немедленно подвергли бы его обратному конструированию и нашли способы обмануть фильтр, заставив его воспринимать спам как желательную почту. Во многих случаях данные «зашумлены», например неправильно помечены или содержат ошибочные признаки, – и тогда было бы даже вредно чересчур усердно стараться найти модель, которая корректно классифицирует обучающие данные, поскольку она оказалась бы переобученной и не обобщалась бы на новые данные. Бывает, что признаки, использованные для описания данных, дают лишь предположительное указание

о возможном классе, но не содержат достаточно сильного «сигнала», который позволил бы с уверенностью предсказать класс. По этим и другим причинам специалисты по машинному обучению очень серьезно подходят к оценке качества работы алгоритмов обучения, и мы также уделим этому вопросу много внимания. Нам нужно составить хоть какое-то представление о том, как алгоритм будет работать на новых данных, не с точки зрения быстродействия или потребления памяти (хотя и это важно), а в терминах правильности классификации (если перед нами стоит задача классификации).

Допустим, требуется выяснить, насколько хорошо работает наш свежеобученный фильтр спама. Можно, например, подсчитать количество правильно классифицированных сообщений, спамных и хороших, и разделить его на общее число предъявленных примеров. В результате мы получим величину, называемую *верностью* (accuracy) классификатора. Однако она ничего не говорит о наличии переобученности. Лучше было бы поступить иначе: использовать только часть имеющихся данных (скажем, 90%) для обучения, а оставшуюся часть – в качестве *тестового набора*. Если имеет место переобучение, то на тестовом наборе алгоритм покажет гораздо худшие результаты, чем на обучающем. Но даже если выбирать данные для тестового набора случайно, нельзя исключить, что нам повезет, – большинство элементов тестового набора похожи на элементы обучающего набора – или, наоборот, не повезет – все элементы тестового набора окажутся нетипичными или зашумленными. Поэтому на практике разбиение данных на обучающие и тестовые повторяется, этот процесс, называемый ☞ *перекрестной проверкой*, мы рассмотрим подробнее в главе 12. Идея такова: мы случайно разбиваем данные на десять групп одинакового размера, из них девять групп используются для обучения, а одна – для тестирования. Обучение повторяется десять раз, и каждый раз для тестирования берется новая группа. В конце мы вычисляем среднее значение качества работы на тестовом наборе (и обычно также его стандартное отклонение, поскольку оно позволяет сказать, значимы ли небольшие расхождения в вычисленном среднем значении показателя качества для различных алгоритмов обучения). Перекрестную проверку можно применять и к другим проблемам обучения с учителем, но качество методов обучения без учителя обычно оценивается по-другому.

В главах 2 и 3 мы гораздо подробнее рассмотрим различные задачи, которые поддаются решению с помощью методов машинного обучения. В каждом случае мы поставим задачу и изучим различные варианты. Мы будем обращать особое внимание на оценку качества моделей, обученных для решения задач, поскольку это позволит глубже понять природу самих задач.

Задолго до появления машинного обучения философы понимали, что переход от частных случаев к общим правилам – это не четко поставленная задача, имеющая однозначное решение. Способ вывода путем обобщения называется *индукцией* в противоположность *дедукции* – способу рассуждений, применимому к задачам, имеющим четко определенное правильное решение.

Существует много вариантов так называемой *проблемы индукции*. Один из них был сформулирован шотландским философом XVIII века Дэвидом Юмом, который утверждал, что единственное обоснование индукции само по себе носит индуктивный характер: из того, что методика работает для некоторых индуктивных проблем, делается вывод, что она будет работать и для всех таких проблем. Здесь утверждается не просто, что индукцию невозможно обосновать дедуктивно, а что ее обоснование ведет к порочному кругу, – и это гораздо хуже.
Близкой проблеме посвящена *теорема о бесплатных завтраках*, которая утверждает, что ни один алгоритм не может быть лучше всех остальных на любой возможной задаче классификации и что средняя эффективность любого алгоритма обучения на множестве всех возможных проблем обучения не лучше случайной догадки. Рассмотрим, к примеру, вопрос типа «угадай следующее число», популярный в психологических тестах: как продолжить последовательность 1, 2, 4, 8, ...? Если все числовые последовательности равновероятны, то нет никакой надежды, что мы сможем как-то улучшить – в среднем – случайную догадку (лично я на такие вопросы всегда отвечаю 42). Разумеется, некоторые последовательности выглядят намного вероятнее прочих, по крайней мере в психологических тестах. Точно так же и распределение проблем обучения в реальном мире весьма далеко от равномерного. И чтобы уйти от проклятья теоремы о бесплатных завтраках, нужно выяснить как можно больше об этом распределении и воспользоваться этим знанием при выборе алгоритма обучения.

Замечание 1.1. Проблемы индукции и бесплатные завтраки

1.2 Модели: результат машинного обучения

Модели – центральная концепция машинного обучения, поскольку это именно то, что порождается в результате обучения на данных с целью решения поставленной задачи. Разнообразие моделей чрезвычайно – даже обескураживающе – велико. И одна из причин этого феномена – разнообразие задач, решаемых методами машинного обучения: классификация, регрессия, кластеризация, выявление ассоциаций – и это только небольшая выборка. Примеры встречаются практически в любой отрасли науки и техники. Математики, инженеры, психологи, специалисты по информатике и многие другие ученые открывали – а иногда и переоткрывали – способы решения таких задач. Все они принесли на общий алтарь свои специфические навыки, и потому принципы, лежащие в основе моделей, существенно разнятся. Лично я считаю, что это хорошо, поскольку благодаря разнообразию машинное обучение оказывается более эффективной и интересной научной дисциплиной. Однако это отнюдь не облегчает задачу, стоящую перед автором книги по машинному обучению! К счастью, можно выделить несколько общих тем, что позволяет мне внести некоторую систематичность в обсуждение моделей машинного обучения. Я буду рассматривать три группы моделей: геометрические, вероятностные и логические. Они не являются взаимно исключающими, иногда встречаются модели, допускающие как геометрическую, так и вероятностную интерпретацию. Но в качестве отправной точки для наших изысканий такой классификации вполне достаточно.

Геометрические модели

Пространством объектов называется множество всех возможных или описываемых объектов вне зависимости от того, присутствуют они в имеющемся наборе данных или нет. Обычно это множество имеет некую геометрическую структуру. Например, если все признаки числовые, то каждый признак можно рассматривать как точку в декартовой системе координат. *Геометрическая модель* строится в пространстве экземпляров с применением таких геометрических понятий, как прямые, плоскости и расстояния. Например, линейный классификатор, изображенный на рис. 1, является геометрическим классификатором. Главное достоинство геометрических классификаторов заключается в простоте их визуализации, по крайней мере в двухмерном и трехмерном пространстве. Однако важно понимать, что размерность декартова пространства объектов равна количеству признаков, а их могут быть десятки, сотни, тысячи и даже больше. Пространства столь высокой размерности наглядно представить сложно, но в машинном обучении они встречаются сплошь и рядом. В названиях геометрических понятий, потенциально применимых к многомерным пространствам, обычно присутствует префикс «гипер», например решающая граница называется *гиперплоскостью*.

Если существует линейная решающая граница, разделяющая два класса, то говорят, что данные *линейно разделимы*. Как мы видели, линейная решающая граница определяется уравнением $\mathbf{w}\cdot\mathbf{x} = t$, где $\mathbf{w}$ – вектор, перпендикулярный решающей границе, а t – порог принятия решения. Вектор $\mathbf{w}$ удобно представлять себе как вектор, соединяющий «центр масс» отрицательных объектов $\mathbf{n}$ с центром масс положительных объектов $\mathbf{p}$. Иными словами, $\mathbf{w}$ пропорционален (или равен) $\mathbf{p}$-$\mathbf{n}$. Вычислить положения центров масс можно с помощью усреднения. Например, если P – множество n положительных примеров, то можно определить $\mathbf{p} = (1/n)\Sigma_{x\in P}\mathbf{x}$, и аналогично для $\mathbf{n}$. Задав подходящим образом порог принятия решения, мы сможем сделать так, чтобы точка пересечения с отрезком, соединяющим $\mathbf{n}$ с $\mathbf{p}$, находилась точно посередине (рис. 1.1). В этом случае мы будем говорить о *базовом линейном классификаторе*[1]. Его достоинством является простота, поскольку он определяется только в терминах сложения, вычитания и умножения векторов-примеров на число (иначе говоря, $\mathbf{w}$ – *линейная комбинация* примеров). На самом деле, как мы увидим ниже, при некоторых дополнительных предположениях о данных это лучшее, на что можно надеяться. Но если эти предположения не выполняются, то базовый линейный классификатор ведет себя плохо – например, он может неидеально отделять отрицательные объекты от положительных, даже если данные линейно разделимы.

Поскольку данные обычно зашумлены, линейная разделимость на практике встречается редко, если только данные не являются сильно разреженными, как в случае классификации текстов. Напомним, что мы использовали большой словарь, порядка 10 000 слов, и каждому слову соответствует булев признак, описы-

[1] Это упрощенный вариант линейных дискриминантов.

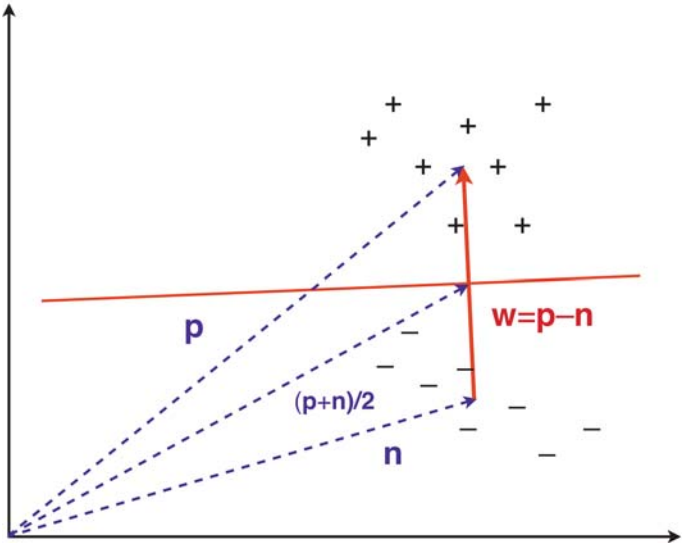

Рис. 1.1. Базовый линейный классификатор строит решающую границу путем проведения прямой через середину отрезка, соединяющего центры масс положительных и отрицательных примеров. Он описывается уравнением $\mathbf{w}\cdot\mathbf{x} = t$, где $\mathbf{w} = \mathbf{p} - \mathbf{n}$; порог принятия решения можно найти, заметив, что вектор $(\mathbf{p} + \mathbf{n})/2$ находится на решающей границе, поэтому $t = (\mathbf{p} - \mathbf{n}) \cdot (\mathbf{p} + \mathbf{n})/2 = (\|\mathbf{p}\|^2 - \|\mathbf{n}\|^2)/2$, где $\|\mathbf{x}\|$ – длина вектора $\mathbf{x}$

вающий, встречается это слово в документе или нет. Это означает, что размерность пространства объектов равна 10 000, но для любого документа лишь очень небольшая доля признаков отлична от нуля. Поэтому между объектами много «пустого места», что повышает шансы на линейную разделимость. Но поскольку решающая граница в случае линейно разделимых данных определена неоднозначно, то возникает следующий вопрос: какую из бесконечного множества решающих границ выбрать? Естественно было бы предпочесть классификаторы с большим зазором, где под *зазором* линейного классификатора понимается расстояние между решающей границей и ближайшим к ней объектом. ☞ *Метод опорных векторов*, рассматриваемый в главе 7, – пример алгоритма линейной классификации, который ищет решающую границу с максимальным зазором (рис. 1.2).

Геометрические идеи, в частности линейные преобразования, могут оказаться весьма полезны для понимания сходства и различия методов машинного обучения (замечание 1.2). Например, мы ожидаем, что большинство алгоритмов обучения (если не все) инвариантно относительно параллельного переноса, то есть не зависит от того, где поместить начало координат. Некоторые алгоритмы инвариантны также относительно вращения, например линейные классификаторы и метод опорных векторов. Но далеко не все – скажем, байесовский классификатор к таковым не относится. Существуют также алгоритмы, чувствительные к непропорциональному масштабированию.

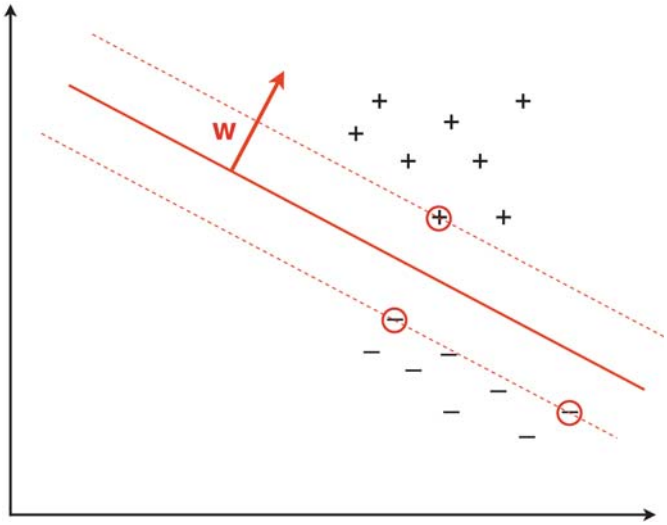

Рис. 1.2. Решающая граница, найденная методом опорных векторов для линейно разделимых данных, показанных на рис. 1.1. При таком выборе решающей границы максимизируется зазор, обозначенный пунктирными линиями. Точки, обведенные кружочками, – опорные векторы

Очень полезно в машинном обучении геометрическое понятие *расстояния*. Если расстояние между двумя объектами мало, то эти объекты похожи с точки зрения значений их признаков, и можно ожидать, что близким объектам будет сопоставлен один и тот же класс или что они попадут в один и тот же кластер. В декартовой системе координат для измерения расстояния можно взять *евклидову метрику* – квадратный корень из суммы квадратов расстояний вдоль каждой координаты[1]: $\sqrt{\sum_{i=1}^{d}(x_i - y_i)^2}$. Очень простой метрический классификатор работает следующим образом: чтобы классифицировать новый экземпляр, мы находим самый похожий на него пример из обучающего набора (то есть объект, для которого евклидово расстояние до классифицируемого объекта минимально) и назначаем классифицируемому объекту тот же класс, что у этого примера. Это *классификатор по ближайшему соседу*. На эту тему существуют бесчисленные вариации: можно взять k самых похожих примеров и организовать голосование (метод k ближайших соседей); можно присвоить голосу каждого соседа вес, обратно пропорциональный расстоянию до него; можно применить ту же идею к задачам регрессии, усреднив значения функции для обучающих примеров, и т. д. У всех этих методов есть общая черта – их предсказания локальны в том

[1] В векторных обозначениях это можно записать в виде $\|\mathbf{x} - \mathbf{y}\| = \sqrt{(\mathbf{x} - \mathbf{y}) \cdot (\mathbf{x} - \mathbf{y})} = \sqrt{\mathbf{x} \cdot \mathbf{x} - 2\mathbf{x} \cdot \mathbf{y} + \mathbf{y} \cdot \mathbf{y}} = \sqrt{\|\mathbf{x}\|^2 - 2\|\mathbf{x}\|\|\mathbf{y}\|\cos\theta + \|\mathbf{y}\|^2}$, где θ – угол между $\mathbf{x}$ и $\mathbf{y}$.

смысле, что основаны на нескольких обучающих примерах, а не на глобальной модели, построенной по всему набору данных.

Преобразования в d-мерной декартовой системе координат удобно представлять в матричной форме. Пусть $\mathbf{x}$ – d-мерный вектор, представляющий точку, и $\mathbf{t}$ – еще один d-мерный вектор, тогда $\mathbf{x} + \mathbf{t}$ – точка, полученная *параллельным переносом* на вектор $\mathbf{t}$. Параллельный перенос множества точек на вектор $\mathbf{t}$ – то же самое, что параллельный перенос начала координат на вектор $-\mathbf{t}$. В *однородных координатах* (получаются путем добавления дополнительной координаты, равной 1) параллельный перенос можно записать в виде умножения на матрицу. Например, в двухмерном пространстве имеем:

$$\mathbf{x}^\circ = \begin{pmatrix} 1 \\ x_1 \\ x_2 \end{pmatrix}; \quad \mathbf{T} = \begin{pmatrix} 1 & 0 & 0 \\ t_1 & 1 & 0 \\ t_2 & 0 & 1 \end{pmatrix}; \quad \mathbf{T}\mathbf{x}^\circ = \begin{pmatrix} 1 \\ x_1 + t_1 \\ x_2 + t_2 \end{pmatrix}.$$

Вращение, или *поворот*, определяется матрицей $\mathbf{D}$ размерности $d \times d$, для которой транспонированная матрица совпадает с обратной (то есть матрица ортогональна), а определитель равен 1. В двухмерном пространстве матрицу поворота вокруг начала координат на угол θ по часовой стрелке можно записать в виде $\mathbf{R} = \begin{pmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{pmatrix}$. Например, поворот на 90° по часовой стрелке описывается матрицей $\begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix}$.

Масштабирование определяется диагональной матрицей; в двухмерном пространстве $\mathbf{S} = \begin{pmatrix} s_1 & 0 \\ 0 & s_2 \end{pmatrix}$.

В случае пропорционального масштабирования ко всем измерениям применяется один и тот же масштабный коэффициент s, так что матрицу можно записать в виде $s\mathbf{I}$, где $\mathbf{I}$ – единичная матрица. Отметим, что пропорциональное масштабирование с коэффициентом -1 совпадает с поворотом (на 180° в двухмерном случае).

Преобразования обычно используются следующим образом. Если дана матрица $\mathbf{X}$ размерности $n \times d$, представляющая n точек в d-мерном пространстве, то сначала вычисляется центр масс, или средний вектор μ, путем нахождения среднего арифметического значений в каждом столбце. Затем этот центр делается началом координат путем прибавления $-\mu$ к каждой строке, что соответствует параллельному переносу. Далее мы вращаем данные, так чтобы рассеяние (мера «разброса» данных в некотором направлении) по возможности было сосредоточено вдоль осей координат; это можно сделать с помощью преобразования матрицы, которое называется ☞ *методом главных компонент* (см. главу 10). И наконец, мы масштабируем данные, так чтобы рассеяние вдоль каждой оси было равно единице.

Замечание 1.2. Линейные преобразования

Имеется интересная связь между евклидовым расстоянием и средней точкой, или центроидом множества точек: не существует точки, для которой сумма квадратов расстояний до каждой точки множества была бы меньше, чем та же сумма для центроида множества (доказательство см. в теореме 8.1). Следовательно, центроид множества точек можно считать *эталоном* этого множества. Предположим, что требуется распределить данные по K кластерам, и у нас есть предва-

рительное предположение о том, как это распределение должно выглядеть. Тогда мы вычисляем центроиды начальных кластеров и переносим каждую точку в тот кластер, к центроиду которого она ближе всего. Если наша гипотеза была неточна, то в результате некоторые кластеры изменятся. Поэтому мы повторяем описанные шаги (вычисление центроидов и перераспределение точек между кластерами) до тех пор, пока не прекратятся изменения. Этот алгоритм кластеризации, подробно обсуждаемый в главе 8, называется ☞ *методом K средних* и широко применяется для решения различных задач кластеризации. Остается еще определить, как строится начальная гипотеза. Обычно это делается случайным образом: либо множество данных случайно распределяется по K «кластерам», либо случайно выбираются K «центроидов кластеров». И хотя начальные «кластеры» или «центроиды кластеров», скорее всего, имеют мало общего с реальностью, это не страшно, потому что после нескольких итераций алгоритма все придет в норму.

Подведем итог. Геометрические понятия – плоскости, параллельный перенос, поворот и расстояние – оказываются весьма полезны в машинном обучении, потому что позволяют интуитивно осмыслить многие ключевые концепции. Геометрические модели, основанные на этих интуитивных представлениях, просты, эффективны и допускают многочисленные вариации. Так, вместо евклидова расстояния, чувствительного к выбросам, можно использовать другие метрики, например манхэттенское расстояние – сумму расстояний вдоль осей: $\Sigma_{i=1}^{d}|x_i - y_i|$.

Вероятностные модели

Существуют также модели вероятностного характера, как, например, рассмотренный выше байесовский классификатор. Многие из них основаны на следующей идее. Обозначим X множество известных нам переменных, например значения признаков объектов, а Y – множество интересующих нас *целевых переменных*, например классы объектов. Основной вопрос машинного обучения – как смоделировать взаимосвязь между X и Y. Статистический подход заключается в том, чтобы предположить существование некоего случайного процесса, который порождает значения целевых переменных, подчиняющиеся вполне определенному, но неизвестному нам распределению вероятностей. Мы хотим использовать имеющиеся данные, чтобы как можно больше узнать об этом распределении. Но сначала подумаем, как можно было бы воспользоваться распределением, после того как мы что-то узнаем о нем.

Поскольку X для конкретного объекта известно, а Y, возможно, нет, то нам особенно интересны условные вероятности $P(Y|X)$. Например, Y может указывать, является почтовое сообщение спамом или нет, а X – информация о том, содержит ли сообщение слова «виагра» и «лотерея». Тогда нас интересует вероятность $P(Y|\text{виагра}, \text{лотерея})$, где виагра и лотерея – булевы переменные, вместе составляющие вектор признаков X. Для любого конкретного сообщения значения этих признаков известны, поэтому можно написать $P(Y|\text{виагра} = 1, \text{лотерея} = 0)$, если сообщение содержит слово «виагра», но не содержит слова «лотерея». Эта